



Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Dirección: José Rouco Maseda e Jorge Novo Buján

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña



Índice de Contidos

- 1 Introducción e Motivación
- 2 Contexto e Estado da Arte
- 3 Metodoloxía Proposta
- 4 Experimentos e Resultados
- 5 Conclusións e Traballo Futuro



Tabla de contenidos



- 1 **Introdución e Motivación**
- 2 Contexto e Estado da Arte
- 3 Metodoloxía Proposta
- 4 Experimentos e Resultados
- 5 Conclusións e Traballo Futuro



O Problema Clínico: Alinhamento de Imaxes de Retina

Necesidade Clínica

- O alinhamento de imaxes de retina é fundamental para:
 - Rastrear a progresión de enfermidades como o glaucoma ou a retinopatía diabética.
 - Fusionar información de distintas fontes, como retinografía e OCT.
- O ollo permite a observación directa de tecido neuronal e vasos sanguíneos, clave para o diagnóstico precoz.






O Reto do Aliñamento Manual

O Reto

O aliñamento manual é un proceso:

- Tedioso e lento: consume tempo dos especialistas.
- Subxectivo e propenso a erros: depende do experto.
- Non escalable: inviable para grandes volumes de datos.

→ A automatización é de gran interese clínico.



Imaxe fixa, móbil, deformada e resultado superposto.



Obxectivos do Traballo

O obxectivo principal é explorar a viabilidade das Representacións Neurais Implícitas (INRs) para o aliñamento de imaxes oftalmolóxicas.

Obxectivos específicos:

- 1 Adaptar o framework IDIR: Modificar a arquitectura orixinal, pensada para imaxes 4D-CT de pulmóns, para rexistro en 2D de retina.
- 2 Avaliar o rendemento: Comparar o método en dous conxuntos de datos:
 - FIRE: Imaxes clínicas reais, con variabilidade do mundo real.
 - RFMID: Imaxes sintéticas con transformacións coñecidas.
- 3 Analizar a os resultados: En particular se a activación SIREN ofrece vantaxes para capturar deformacións.



Tabla de contenidos

- 1 Introducción e Motivación
- 2 Contexto e Estado da Arte
- 3 Metodoloxía Proposta
- 4 Experimentos e Resultados
- 5 Conclusións e Traballo Futuro





Rexistro Deformable: Campo de Vectores de Deformación

Rexistro Deformable

Atopar unha transformación non ríxida que mapea cada coordenada x da imaxe móbil á súa localización correspondente na imaxe fixa.

- Modélase como un Campo de Vectores de Deformación (DFV), que indica o desprazamento de cada punto.
- Tradicionalmente represéntase o DFV nunha grella discreta de píxeles. Isto ten limitacións de resolución e memoria.





Representacións Neuronais Implícitas (INRs)

Representacións Neuronais Implícitas (INRs)

En lugar dunha grella, representamos a transformación como unha función continua, parametrizada polos pesos dunha rede neuronal (MLP).

- Entrada: Coordenada (x, y) .
- Saída: Vector de desprazamento (dx, dy) .
- Vantaxes clave:
 - Independencia da resolución: A función é continua, non depende do tamaño da imaxe.
 - Gradientes analíticos: Permite calcular derivadas exactas da deformación, crucial para unha regularización precisa.



O Problema do Sesgo Espectral

Limitación das Redes con ReLU

As funcións de activación lineais coma ReLU presentan un sesgo espectral cara funcións de baixa frecuencia (transformacións globais e ríxidas), e teñen dificultades para representar detalles finos e cambios locais.

No contexto do rexistro de retinas, isto é problemático porque os detalles de alta frecuencia son críticos para un aliñamento preciso.



SIREN (Sinusoidal Representation Networks)

A Solución:

SIREN utiliza a función seno como activación para superar o sesgo espectral e modelar detalles finos.

$$f(x) = \sin(ax + b), \quad \text{con } a, b \in \mathbb{R}$$

- Ideal para sinais complexos: Permite representar detalles de alta frecuencia e as súas derivadas.
- Infinitamente diferenciable: A diferenza de ReLU, a función seno pode derivarse tantas veces sexa necesario, permitindo regularizacións de orde superior como a "Bending Energy".



Tabla de contenidos

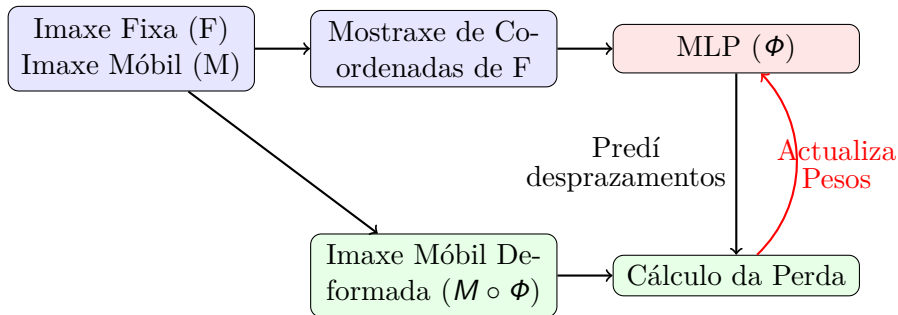
- ① Introducción e Motivación
- ② Contexto e Estado da Arte
- ③ Metodoloxía Proposta**
- ④ Experimentos e Resultados
- ⑤ Conclusións e Traballo Futuro



Framework IDIR: Esquema do Proceso

Optimización por Par de Imaxes

A metodoloxía de IDIR adestra unha nova rede para cada par de imaxes (Fixa F e Móbil M).





Framework IDIR: Función de Perda

Función de Perda

A rede optimízase para minimizar unha perda combinada:

$$\hat{\phi} = \text{Arg min}_{\phi} L_{data}(M \circ \phi, F) + \alpha L_{reg}(\phi)$$

- \mathcal{L}_{datos} : Mide a similitude entre a imaxe fixa e a móbil deformada (e.g., NCC).
- \mathcal{L}_{reg} : Penaliza as deformacións non realistas para garantir a suavidade.




Framework IDIR: Regularización


Problema:

O rexistro de imaxes é un "ill-posed problem": existen moitas deformacións que poden facer que as imaxes se parezan, pero a maioría non son solucións correctas (non fisicamente realistas).

A regularización engade coñecemento previo físico para restrinxir o espazo de solucións posibles.



Sen regularización: pregamentos non físicos.



Exceso de regularización: deformación demasiado ríxida.



Framework IDIR: Regularizador Xacobiano

- Controla a distorsión local da área e prevé pregamentos (folding) non realistas na deformación, evitando compresións ou estiramentos extremos.
- Mecanismo: Penaliza as desviacións do determinante da matriz Xacobiana ($\det \nabla \Phi$) respecto do valor 1.
 - Un determinante próximo a 1 preserva a área local.
 - Un determinante negativo ou cero indica un pregamento da malla, o que invalida a transformación.

$$S^{\text{jac}}[\Phi] = \int_{\Omega} |1 - \det(\nabla \Phi)| \, dx \, dy$$



Framework IDIR: Regularizador Hiperelástico

- Mecanismo: Combina termos que penalizan a variación da lonxitude dos vectores de desprazamento e as distorsións de área.
 - O termo $|\nabla u|^2$ controla o estiramento.
 - O termo co cofactor (cof) controla a deformación da área.
- É un regularizador máis xeral que engloba propiedades do Xacobiano e impón unha certa suavidade.

$$S^{\text{hyper}}[\phi] = \int_{\Omega} \left[\frac{1}{2} \alpha_I |\nabla u|^2 + \alpha_a \varphi_c(\text{cof} \nabla \phi) \right] dx dy$$

con

$$\varphi_c(C) = \sum_{i=1}^2 \max \left\{ \sum_{j=1}^2 C_{ji}^2 - 1, 0 \right\}^2$$



Framework IDIR: Regularizador de Enerxía de Flexión

- Evita cambios bruscos na curvatura do campo de desprazamento, o que se traduce en transformacións visualmente mais suaves e continuas.
- Penaliza a magnitude das segundas derivadas parciais do campo de deformación (Φ) en todo o dominio.

$$S^{\text{bending}}[\Phi] = \frac{1}{8} \int_{\Omega} \left[\left(\frac{\partial^2 \Phi}{\partial x^2} \right)^2 + \left(\frac{\partial^2 \Phi}{\partial y^2} \right)^2 + 2 \left(\frac{\partial^2 \Phi}{\partial x \partial y} \right)^2 \right] dx dy$$



Consideracións sobre a Regularización

- Balance da regularización: É crucial atopar un equilibrio no peso dos termos de regularización.
- Custo computacional: A regularización incrementa significativamente o tempo de cómputo, xa que require calcular gradientes adicionais por época.

Vantaxe SIREN

O cálculo de regularizadores de orde superior (como a Enerxía de Flexión) de forma eficiente e analítica só é posible porque as redes SIREN son infinitamente diferenciáveis. Arquitecturas baseadas en ReLU non poden usar este termo, xa que a súa segunda derivada é cero en case todos os puntos.



Tabla de contenidos


- 1 Introducción e Motivación
- 2 Contexto e Estado da Arte
- 3 Metodoloxía Proposta
- 4 Experimentos e Resultados**
- 5 Conclusións e Traballo Futuro



Contorno Experimental: Datasets e Métricas

Datasets de Avaliación

- FIRE [1]:
 - 134 pares de imaxes clínicas reais.
 - Inclúe variacións de iluminación, contraste, e patoloxías.
 - Baixa superposición nalgúnhas imaxes.
 - Proba de robustez no mundo real.
- RFMID (Sintético) [1]:
 - Xeramos pares de imaxes aplicando transformacións



figureExemplos do dataset FIRE.
De esquerda a dereita: categorías
S, P, A. Adaptado de. [1]




Resultados Cuantitativos: ReLU vs. SIREN

Achado Principal: O rendemento depende da complexidade do problema

Non hai un gañador absoluto. A arquitectura óptima depende da natureza da transformación a aprender.

Método	Dataset	Dist. Media (px) ↓
MLP-ReLU	RFMID (Sinxelo)	
MLP-SIREN	RFMID (Sinxelo)	
MLP-ReLU	FIRE (Complexo)	
MLP-SIREN	FIRE (Complexo)	

tableResumo simplificado dos resultados. Datos de.[1]



Outros achados clave:



UNIVERSIDADE DA CORUÑA

• O tamaño do lote (batch size)

Mateo Amado Ares

Xuño de 2025

22/28




Análise Cualitativa: Éxitos e Fracasos

Unha imaxe vale máis que mil números


A avaliación visual é crucial para entender como e por que o método funciona ou falla.

Rexistro Exitoso (RFMiD,
ReLU)



A superposición en modo checkerboard mostra unha continuidade perfecta dos vasos sanguíneos. A grella de deformación é suave.

Rexistro Fallido (RFMiD,
ReLU)



Os vasos están rotos na superposición. A grella de deformación mostra pregamentos non físicos, un síntoma de sobreaxuste local.



Tabla de contenidos

- 1 Introducción e Motivación
- 2 Contexto e Estado da Arte
- 3 Metodoloxía Proposta
- 4 Experimentos e Resultados
- 5 Conclusións e Traballo Futuro



Conclusións Principais

- ① Adaptación viable pero con limitacións: Demostrouse que é posible adaptar o framework IDIR para o rexistro de imaxes de retina 2D. Non obstante, o seu rendemento é moi sensible á complexidade da transformación e á calidade das imaxes.[1]
- ② Non hai unha arquitectura universalmente superior: A elección da función de activación é un compromiso.
 - ReLU é máis eficaz para transformacións sinxelas e globais (como no noso dataset sintético RFMID).
 - SIREN ten unha lixeira vantaxe en deformacións complexas e locais (dataset real FIRE), pero é máis propenso a converxer a malos mínimos locais se non se regulariza coidadosamente.[1]
- ③ Principais desafíos identificados: O rendemento do modelo degradase significativamente ante dous escenarios comúns



Liñas de Traballo Futuro: Cara a un Enfoque Híbrido

Diagnóstico do Problema

A nosa análise revela que o método INR é bo para o refinamento local de deformacións complexas, pero malo para atopar a correspondencia global cando os desprazamentos son grandes.[1]

Proposta de Solución: Un Enfoque Híbrido

Propomos un sistema de dous pasos que combina o mellor de dous mundos, inspirado en traballos de vangarda como HybridRetina [1, 11, 12]:

Paso 1: Rexistro Global

Robusto

- Usar un método baseado en características para obter un aliñamento inicial

Paso 2: Refinamento Local con
INR

- Usar o noso modelo IDIR-SIREN sobre as





Grazas pola atención.



Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Dirección: José Rouco Maseda e Jorge Novo Buján

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña