



Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña





Tabla de contenidos

- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro





Tabla de contenidos

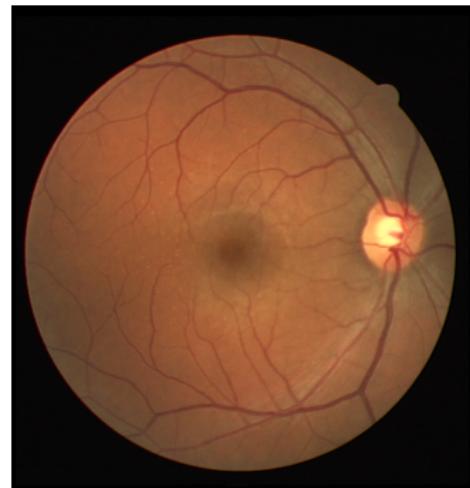
- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro





Introducción y Motivación: Retinografía

Diferentes estructuras
retinografía





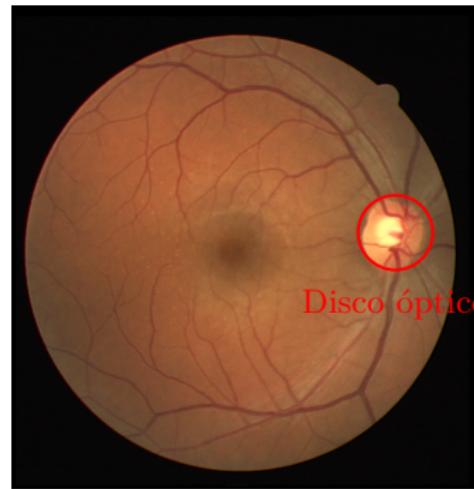
Introducción y Motivación: Retinografía

Diferentes estructuras
retinografía

1 Disco óptico



Disco
óptico

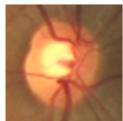
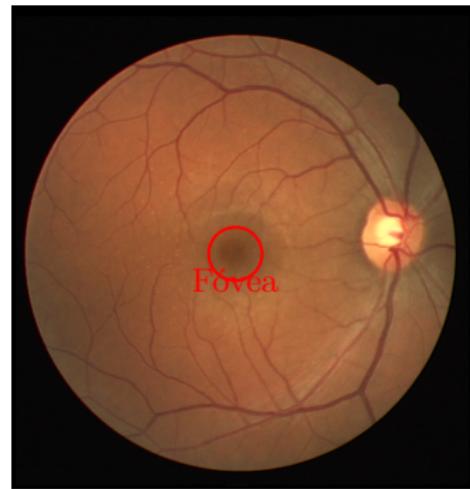




Introducción y Motivación: Retinografía

Diferentes estructuras
retinografía

- ① Disco óptico
- ② Fóvea



Disco
óptico

Fóvea

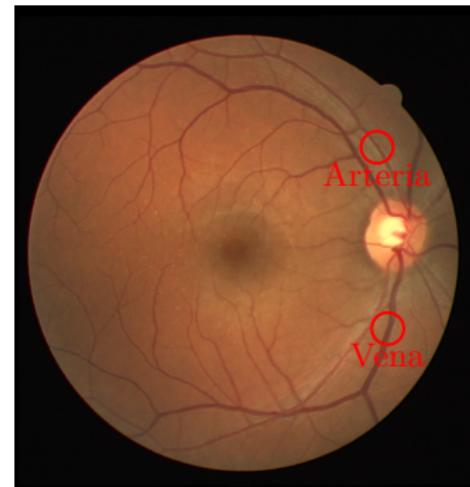




Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

- ① Disco óptico
- ② Fóvea
- ③ Arterias y venas



Disco
óptico



Fóvea



Venas



Arte-
rias

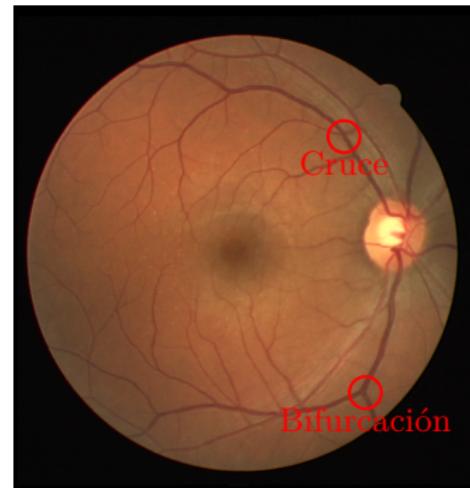




Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

- ① Disco óptico
- ② Fóvea
- ③ Arterias y venas
- ④ Cruces y Bifurcaciones



Disco
óptico



Fóvea



Venas



Arte-
rias



Cruce



Bifur-
cación

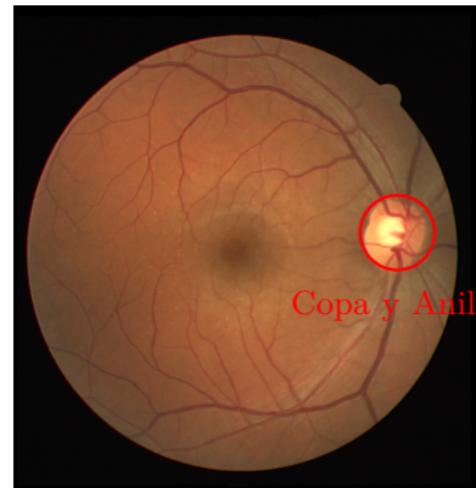




Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

- ① Disco óptico
- ② Fóvea
- ③ Arterias y venas
- ④ Cruces y Bifurcaciones
- ⑤ Anillo y copa del disco óptico



Disco
óptico



Fóvea



Venas



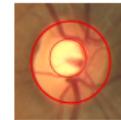
Arte-
rias



Cruce



Bifur-
cación



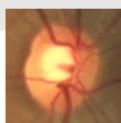
Anillo
y Copo



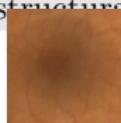


Introducción y Motivación: Extracción de anatomía

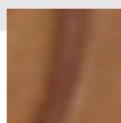
- Proceso manual:
 - Tedioso.
 - Consumo mucho tiempo.
 - Posible fallo humano y subjetividad.
- Necesario para la detección de diferentes enfermedades.
- Solución:
 - Crear un sistema que extraiga estas estructuras.



Disco
óptico



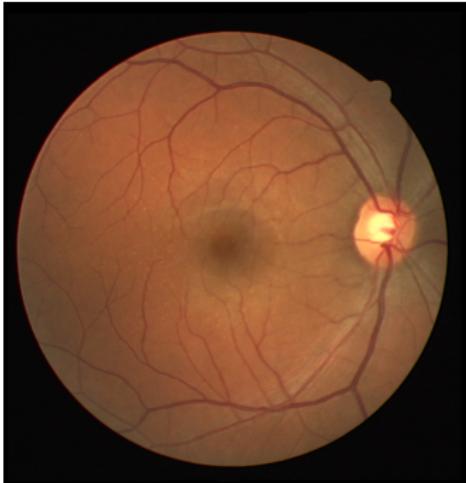
Fóvea



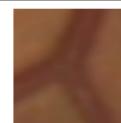
Venas



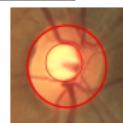
Arte-
rias



Cruce



Bifur-
cación



Anillo
y Copa





Tabla de contenidos

- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro

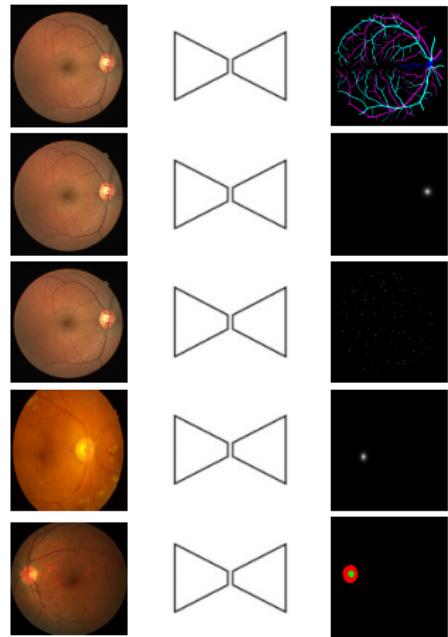




Estado del arte: Estracción de estructuras

Segmentación estructuras retinianas

- Tradicionalmente usando Single Task Learning
 - ① Mucho gasto computacional.
 - ② Falta de transferencia de conocimiento.

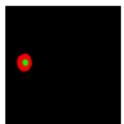
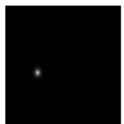
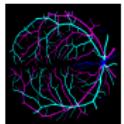
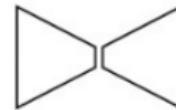




Estado del arte: Propuesta

Propuesta

- Multi Task Learning.
- Ventajas teóricas:
 - ① Compartición de parámetros.
 - ② Transferencia de conocimiento.
- Limitaciones:
 - ① Desbalanceo de tareas.
 - ② Interferencia negativa.





Estado del arte: Propuesta

Posibles soluciones al desbalanceo de tareas.

- Ponderación de losses.
 - Tedioso.
- Uso de arquitecturas especializadas.
- Algoritmos basados en optimización adaptativa.
 - ① DWA
 - ② GradNorm
 - ③ MAO





Estado del arte: Optimización Multi-Adaptativa

MAO

- Basado en algoritmos de optimización adaptativa (ADAM)
 - Adaptan la tasa de aprendizaje de los parámetros del modelo.
- MAO generaliza esta idea a multitarea
 - Adapta la tasa de aprendizaje de cada parámetro de forma independiente para cada tarea.
 - Balancea implícitamente la contribución de cada tarea.

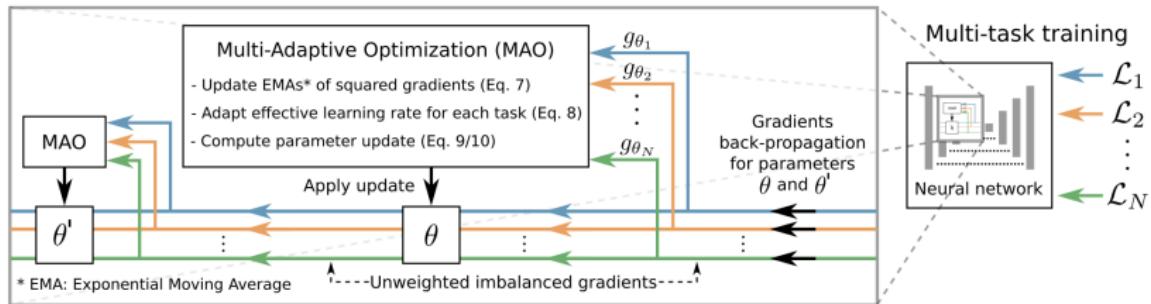




Tabla de contenidos

- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro





Trabajo Desarrollado: Índice

① Single Task Learning

- ① Disco Óptico y Fóvea
- ② Cruces y Bifurcaciones
- ③ Segmentación de Arterias y Venas
- ④ Segmentación Anillo y Copa del Disco Óptico

② Multi Task Learning

③ Arquitecturas

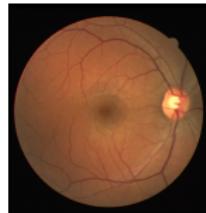




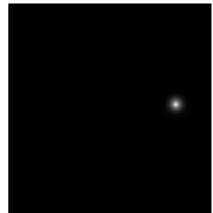
Trabajo Desarrollado: STL

Detección Disco Óptico y Fóvea

- Objetivos:
 - ① Localizar Disco Óptico
 - ② Localizar Fóvea
- Se conoce el centro de la estructura.
 - Mapa binario.
 - Se transforma en un mapa de calor.
- MSE.



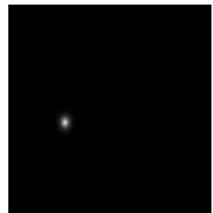
Retinogra-
fía



Disco Óptico



Retinogra-
fía



Fóvea

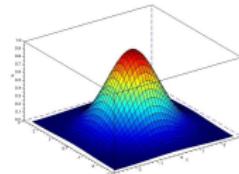




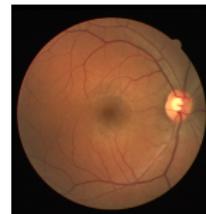
Trabajo Desarrollado: STL

Detección de Cruces y Bifurcaciones

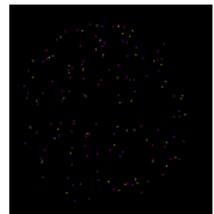
- Objetivos.
 - 1 Localizar los puntos.
 - 2 Distinguir entre Cruces y Bifurcaciones.
- Se conoce la localización de los puntos.
- Un canal para cruces, un canal para bifurcaciones y un canal para el conjunto de cruces y bifurcaciones.
 - Se transforman los mapas binarios en mapas de calor.
- 3 MSE.



Kernel Gaussiano



Retinogra-
fía



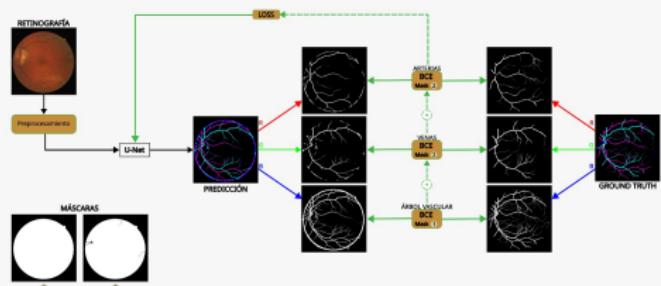
Disco Óptico



Trabajo Desarrollado: STL

Segmentación de arterias y venas.

- Objetivos.
 - 1 Segmentar el árbol vascular.
 - 2 Distinguir entre Arterias y Venas.
- Se divide el problema en tres tareas:
 - Arterias vs fondo.
 - Venas vs fondo.
 - Árbol Vascular vs fondo.
- Multisegmentación.
- 3 BCE.

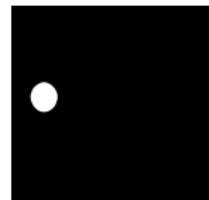




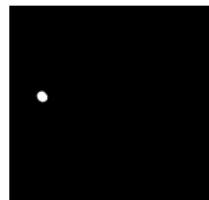
Trabajo Desarrollado: STL

Segmentación de Copa y Anillo del disco óptico

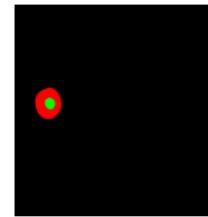
- Objetivos:
 - Segmentar Copa del Disco Óptico.
 - Segmentar Anillo del Disco Óptico.
- Se divide el problema en 3 clases:
 - Copa óptica.
 - Anillo copa óptica.
 - Fondo.
- Segmentación multiclas.
- MCE.



Disco óptico



Copa



Copa y Anillo





Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.



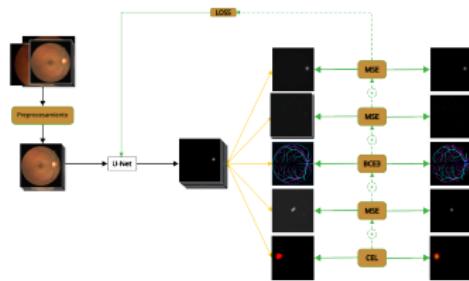
Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.

Baseline

Las pérdidas se suman.

- No se balancean.





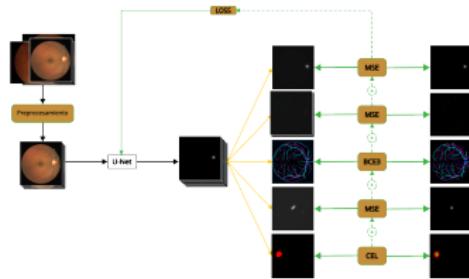
Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.

Baseline

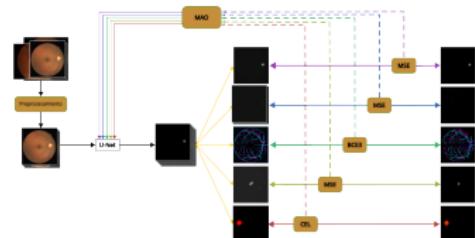
Las pérdidas se suman.

- No se balancean.



MAO

Las pérdidas entran al MAO.

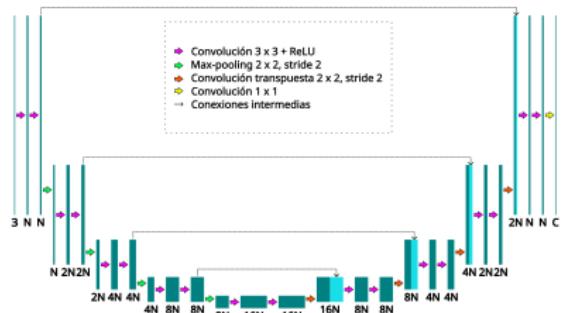




Trabajo Desarrollado: Arquitecturas

U-Net

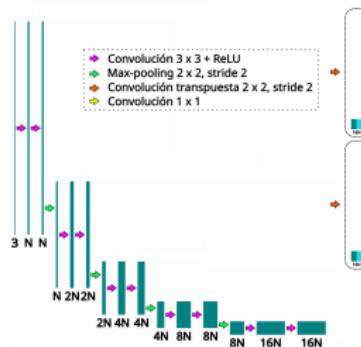
- Muy utilizada en computer vision, especialmente en imagen médica.
- FCN.
- Características:
 - Etapa codificadora.
 - Etapa decodificadora.
 - Conexiones intermedias.



Trabajo Desarrollado: Arquitecturas

Multi Decoder U-Net

- Mismo número de etapas decodificadoras como tareas.



Multi Task U-Net

- Convoluciones finales con grupos con el mismo número que tareas.

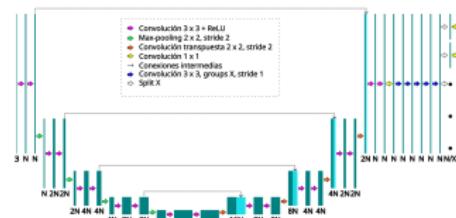




Tabla de contenidos

- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro





Experimentación y Resultados: Iteraciones

Primera Iteración

- ① Entrenar modelos STL, MTL y MAO con U-NET
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados STL son superiores.





Experimentación y Resultados: Iteraciones

Primera Iteración

- ① Entrenar modelos STL, MTL y MAO con U-NET
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados STL son superiores.

Segunda Iteración

- ① Entrenar modelos MTL y MAO con Multi-Decoder U-Net
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados mejoran, pero siguen siendo algo inferiores a STL.





Experimentación y Resultados: Iteraciones

Primera Iteración

- ① Entrenar modelos STL, MTL y MAO con U-NET
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados STL son superiores.

Segunda Iteración

- ① Entrenar modelos MTL y MAO con Multi-Decoder U-Net
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados mejoran, pero siguen siendo algo inferiores a STL.

Tercera Iteración

- ① Entrenar modelos MTL y MAO con Multi-Task U-Net
- ② Evaluar y comparar resultados
 - Se comprueba que los resultados son similares a la anterior iteración.





Experimentación y Resultados: Conjunto de datos

DRIVE/RITE

- 40 imágenes.
- 565×584 píxeles
- Tareas:
 - Detección del Disco Óptico.
 - Detección de Cruces y bifurcaciones.
 - Segmentación de Arterias y Venas.

IDRiD

- 516 imágenes.
- 858×570 píxeles
- Tareas:
 - Detección Fóvea.

REFUGE

- 1200 imágenes.
- 720×697 píxeles
- Tareas:
 - Segmentación de Copa y Anillo del Disco Óptico.





Experimentación y Resultados: Conjunto de datos

Conjunto de datos en MTL

¿Cómo entrenar un modelo MTL si no hay un dataset con todo unificado?

- 11 canales de salida
 - 1 canal Disco óptico
 - 1 canal Fóvea
 - 3 canales Arterias y Venas
 - 3 canales Cruces y bifurcaciones
 - 3 canales Anillo y Copa del Disco óptico
- Cada iteración en entrenamiento, se concatena una imagen de cada dataset.
 - Para poder hacer esto reescalamos las imágenes.
- Calculamos la pérdida de los canales que tenemos etiqueta.





Experimentación y Resultados: Detalles experimentales

- Los entrenamientos se configuran para mejorar la comparación.
- Aumento de datos:
 - Random Horizontal Flip
 - Random Vertical Flip
 - Random HSV
 - Random Affine
- Tasa de aprendizaje constante de 1×10^{-4}
- 500 épocas.
- 100 imágenes por época.
- Optimizador ADAM:
 - En MAO está implícito.





Experimentación y Resultados: Evaluación

Disco Óptico

- ① Error promedio de la localización del Disco.
- ② Desviación estándar.
- ③ Precisión en relación a un umbral.

Arterias y Venas

- ① Curva ROC.
- ② Curva PR.

Cruces y Bifurcaciones

- ① F1-Score.
- ② Precisión media.

Fóvea

- ① Error promedio de la localización de la Fóvea.
- ② Desviación estándar.
- ③ Precisión en relación a un umbral.

Anillo y Copa

- ① Mean dice.
- ② Mean Jaccard.
- ③ Curva PR.

Evaluación Cualitativa

- ① Comparación imagen a imagen de las diferentes tareas.





Resultados.





Experimentación y Resultados: Cruces y Bifurcaciones

- Resultados MTL normalmente inferiores a STL.

Cruces

Modelo	f1-score	Average Precision
MultiMTL	68.12	67.54
STL	72.12	72.47

Bifurcaciones

Modelo	f1-score	Average Precision
MultiMTL	65.96	68.09
STL	67.94	68.29



Experimentación y Resultados: Cruces y Bifurcaciones

- Resultados MTL normalmente inferiores a STL.
- Multi-Decoder U-Net sin MAO supera a STL en el conjunto de cruces y bifurcaciones

Cruces y Bifurcaciones

Modelo	f1-score	Average Precision
MultiMTL	76.78	77.35
STL	74.10	75.36





Experimentación y Resultados: Cruces y Bifurcaciones

	U-Net STL	U-Net MTL	Multi- Task MAO	Multi- Task MTL	Multi- Decoder MAO	Multi- Decoder MTL	Multi- MAO



Experimentación y Resultados: Disco Óptico

- Resultados MTL superiores a STL.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estandar (px)
TaskMAO	100 %	100 %	100 %	3.77	2.16





Experimentación y Resultados: Disco Óptico

- Resultados MTL superiores a STL.
- Aún así, no todos tienen resultados tan buenos.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estandar (px)
MultiMTL	100 %	100 %	95 %	5.52	3.41
UNetMTL	100 %	100 %	90 %	5.14	2.77
STL	100 %	90 %	85 %	7.81	5.90





Experimentación y Resultados: Disco Óptico

	U-Net STL	U-Net MTL	Multi- Task MAO	Multi- Task MTL	Multi- Decoder MAO	Multi- Decoder MTL	Multi- Decoder MAO



Experimentación y Resultados: Fóvea

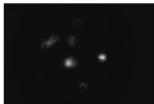
- Resultados con MAO superiores al resto de resultados.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estándar (px)
MultiMAO	93.14 %	88.24 %	78.43 %	16.96	37.86
TaskMAO	91.18 %	84.31 %	73.53 %	19.24	42.47





Experimentación y Resultados: Fóvea

	U-Net STL	U-Net MTL	Multi- Task MAO	Multi- Task MTL	Multi- Decoder MAO	Multi- Decoder MTL	Multi- Decoder MAO
							



Experimentación y Resultados: Arterias y Venas

- Resultados inferiores de MTL frente STL en Venas.

Model	Venas	
	AUC-ROC (%)	AUC-PR (%)
UNetMTL	95.93	76.24
TI	97.45	84.84





Experimentación y Resultados: Arterias y Venas

- Aunque superiores o similares en Arterias y Vasos.

Model	Arterias		Vasos	
	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)
UNetMTL	97.01	82.67	97.82	91.33
TI	96.93	80.10	97.90	91.59





Experimentación y Resultados: Arterias y Venas

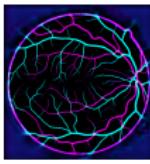
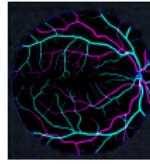
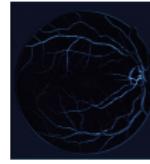
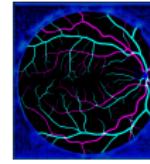
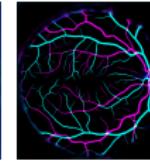
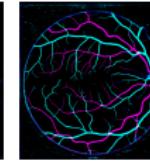
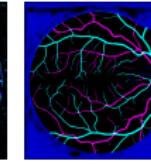
- Único resultado donde U-Net con MAO tiene un resultado aceptable.

Model	Venas		Arterias		Vasos	
	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)
UNetMAO	74.01	22.54	67.94	11.87	72.22	32.56





Experimentación y Resultados: Arterias y Venas

	U-Net STL	U-Net MTL	Multi- Task MAO	Multi- Task MTL	Multi- Task MAO	Multi- Decoder MTL	Multi- Decoder MAO
							



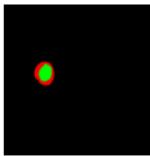
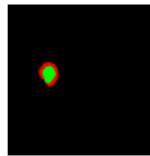
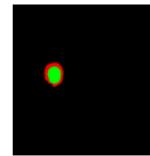
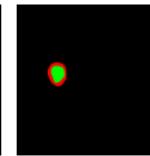
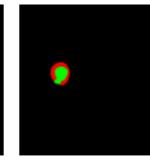
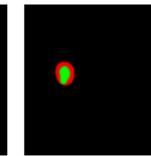
Experimentación y Resultados: Copa y Anillo

- Resultados similares o superiores e Anillo pero inferiores en Copa

Estructura	Anillo			COPA		
	mean dice (%)	mean jaccard (%)	PR-AUC (%)	mean dice (%)	mean jaccard (%)	PR-AUC (%)
MultiMAO	94.95	90.46	99.18	83.22	72.21	91.98
STL	94.51	89.73	99.14	85.69	75.52	94.87



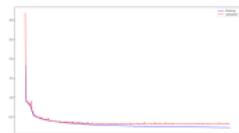
Experimentación y Resultados: Copa y Anillo

	STL MTL	U-Net MAO	U-Net MAO	Multi- Task MTL	Multi- Task MAO	Multi- Decoder MTL	Multi- Decoder MAO
							

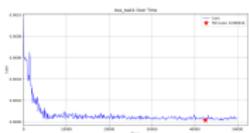


Experimentos y Resultados: Conclusiones

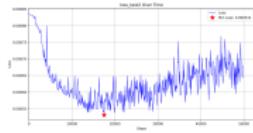
- ① Bajo las condiciones de entrenamiento propuestas, los modelos STL son superiores.
 - Las tareas donde tarda más en empezar el sobreentrenamiento, los resultados compiten con STL.
- ② MAO es dependiente de la arquitectura utilizada.
 - El mal rendimiento de la U-Net confirma esto.



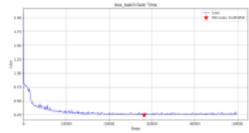
(a)



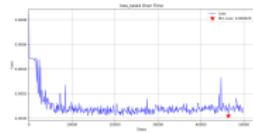
(b)



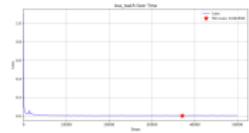
(c)



(d)



(e)



(f)

(a) Pérdida total de Task-Specific U-Net (b)

Disco óptico (c) Cruces y bifurcaciones (d)

SSCAV (e) Fovea (f) Copa y anillo.





Tabla de contenidos

- ① Introducción y Motivación
- ② Estado del arte
- ③ Trabajo Desarrollado
- ④ Experimentación y Resultados
- ⑤ Conclusiones y trabajo futuro





Conclusiones

Trabajo realizado

- Se implementaron modelos MTL sin balanceo de tareas y MAO que satisfactoriamente resuelven las tareas.
- Se adaptaron las condiciones de entrenamiento para mejorar la comparación.
- Se compararon los efectos y resultados de las diferentes aproximaciones con diferentes arquitecturas.
- Se observó dificultades de MTL con MAO para arquitecturas poco específicas.
- Se planteó un posible error en la eficacia de los modelos MTL según el modo actual de entrenamiento.





Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña