Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña

Tabla de contenidos

1. Introducción y Motivación
2. Estado del arte
3. Trabajo Desarrollado
4. Experimentación y Resultados
5. Conclusiones y trabajo futuro

Tabla de contenidos

1. Introducción y Motivación
2. Estado del arte
3. Trabajo Desarrollado
4. Experimentación y Resultados
5. Conclusiones y trabajo futuro

Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

Diferentes estructuras retinografía

1. Disco óptico

Disco óptico

Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

1. Disco óptico
2. Fóvea

Disco óptico

Fóvea

Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

1. Disco óptico
2. Fóvea
3. Arterias y venas

Disco óptico

Fóvea

Venas

Arte-rias

Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

1. Disco óptico
2. Fóvea
3. Arterias y venas
4. Cruces y Bifurcaciones

Disco óptico

Fóvea

Venas

Arte-rias

Cruce

Bifur-cación

Introducción y Motivación: Retinografía

Diferentes estructuras retinografía

1. Disco óptico
2. Fóvea
3. Arterias y venas
4. Cruces y Bifurcaciones
5. Anillo y copa del disco óptico

Disco óptico

Fóvea

Venas

Arte-rias

Cruce

Bifur-cación

Anillo y Copa

Introducción y Motivación: Extracción de anatomía

- Proceso manual:
  - Tedioso.
  - Consume mucho tiempo.
  - Posible fallo humano y subjetividad.
- Necesario para la detección de diferentes enfermedades.
- Solución:
  - Crear un sistema que extraiga estas estructuras.

Disco óptico

Fóvea

Venas

Arte-rias

Cruce

Bifur-cación

Anillo y Copa

Tabla de contenidos

1 Introducción y Motivación

2 Estado del arte

3 Trabajo Desarrollado

4 Experimentación y Resultados

5 Conclusiones y trabajo futuro

Estado del arte: Estracción de estructuras

Segmentación estructuras retinianas

- Tradicionalmente usando Single Task Learning
  1. Mucho gasto computacional.
  2. Falta de transferencia de conocimiento.

Estado del arte: Propuesta

Propuesta

- Multi Task Learning.
- Ventajas teóricas:
  1. Compartición de parámetros.
  2. Transferencia de conocimiento.
- Limitaciones:
  1. Desbalanceo de tareas.
  2. Interferencia negativa.

Estado del arte: Propuesta

Posibles soluciones al desbalanceo de tareas.

- Ponderación de losses.
  - Tedioso.
- Uso de arquitecturas especializadas.
- Algoritmos basados en optimización adaptativa.
  1. DWA
  2. GradNorm
  3. MAO

Estado del arte: Optimización Multi-Adaptativa

MAO

- Basado en algoritmos de optimización adaptativa (ADAM)
  - Adaptan la tasa de aprendizaje de los parámetros del modelo.
- MAO generaliza esta idea a multitarea
  - Adapta la tasa de aprendizaje de cada parámetro de forma independiente para cada tarea.
  - Balancea implícitamente la contribución de cada tarea.

Tabla de contenidos

1 Introducción y Motivación

2 Estado del arte

3 Trabajo Desarrollado

4 Experimentación y Resultados

5 Conclusiones y trabajo futuro

Trabajo Desarrollado: Índice

1. Single Task Learning
   1. Disco Óptico y Fóvea
   2. Cruces y Bifurcaciones
   3. Segmentación de Arterias y Venas
   4. Segmentación Anillo y Copa del Disco Óptico
2. Multi Task Learning
3. Arquitecturas

Trabajo Desarrollado: STL

Detección Disco Óptico y Fóvea

- Objetivos:
  1. Localizar Disco Óptico
  2. Localizar Fóvea
- Se conoce el centro de la estructura.
  - Mapa binario.
  - Se transforma en un mapa de calor.
- MSE.

Retinografía

Disco Óptico

Retinografía

Fóvea

Trabajo Desarrollado: STL

Detección de Cruces y Bifurcaciones

- Objetivos.
  1. Localizar los puntos.
  2. Distinguir entre Cruces y Bifurcaciones.
- Se conoce la localización de los puntos.
- Un canal para cruces, un canal para bifurcaciones y un canal para el conjunto de cruces y bifurcaciones.
  - Se transforman los mapas binarios en mapas de calor.
- 3 MSE.

Kernel Gaussiano

Retinografía

Disco Óptico

Trabajo Desarrollado: STL

Segmentación de arterias y venas.

- Objetivos.
  1. Segmentar el árbol vascular.
  2. Distinguir entre Arterias y Venas.
- Se divide el problema en tres tareas:
  - Arterias vs fondo.
  - Venas vs fondo.
  - Árbol Vascular vs fondo.
- Multisegmentación.
- 3 BCE.

Trabajo Desarrollado: STL

Segmentación de Copa y Anillo del disco óptico

- Objetivos:
  - Segmentar Copa del Disco Óptico.
  - Segmentar Anillo del Disco Óptico.
- Se divide el problema en 3 clases:
  - Copa óptica.
  - Anillo copa óptica.
  - Fondo.
- Segmentación multiclase.
- MCE.

Disco óptico

Copa

Copa y Anillo

Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.

Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.

Baseline

Las pérdidas se suman.

- No se balancean.

Trabajo Desarrollado: MTL

- Entrenar un modelo para las 5 tareas.
- 11 canales de salida.
- Mismas funciones de pérdida que las tareas originales.

Baseline

Las pérdidas se suman.

- No se balancean.

MAO

Las pérdidas entran al MAO.

Trabajo Desarrollado: Arquitecturas

U-Net

- Muy utilizada en computer vision, especialmente en imagen médica.
- FCN.
- Características:
  - Etapa codificadora.
  - Etapa decodificadora.
  - Conexiones intermedias.

Trabajo Desarrollado: Arquitecturas

Multi Decoder U-Net

- Mismo número de etapas decodificadoras como tareas.

Multi Task U-Net

- Convoluciones finales con grupos con el mismo número que tareas.

Tabla de contenidos

1 Introducción y Motivación

2 Estado del arte

3 Trabajo Desarrollado

4 Experimentación y Resultados

5 Conclusiones y trabajo futuro

Experimentación y Resultados: Iteraciones

Primera Iteración

1. Entrenar modelos STL, MTL y MAO con U-NET
2. Evaluar y comparar resultados
   - Se comprueba que los resultados STL son superiores.

Experimentación y Resultados: Iteraciones

Primera Iteración

1. Entrenar modelos STL, MTL y MAO con U-NET
2. Evaluar y comparar resultados
   - Se comprueba que los resultados STL son superiores.

Segunda Iteración

1. Entrenar modelos MTL y MAO con Multi-Decoder U-Net
2. Evaluar y comparar resultados
   - Se comprueba que los resultados mejoran, pero siguen siendo algo inferiores a STL.

Experimentación y Resultados: Iteraciones

Primera Iteración

1. Entrenar modelos STL, MTL y MAO con U-NET
2. Evaluar y comparar resultados
   - Se comprueba que los resultados STL son superiores.

Segunda Iteración

1. Entrenar modelos MTL y MAO con Multi-Decoder U-Net
2. Evaluar y comparar resultados
   - Se comprueba que los resultados mejoran, pero siguen siendo algo inferiores a STL.

Tercera Iteración

1. Entrenar modelos MTL y MAO con Multi-Task U-Net
2. Evaluar y comparar resultados
   - Se comprueba que los resultados son similares a la anterior iteración.

Experimentación y Resultados: Conjunto de datos

DRIVE/RITE

- 40 imágenes.
- 565×584 píxeles
- Tareas:
  - Detección del Disco Óptico.
  - Detección de Cruces y bifurcaciones.
  - Segmentación de Arterias y Venas.

IDRiD

- 516 imágenes.
- 858×570 píxeles
- Tareas:
  - Detección Fóvea.

REFUGE

- 1200 imágenes.
- 720×697 píxeles
- Tareas:
  - Segmentación de Copa y Anillo del Disco Óptico.

Experimentación y Resultados: Conjunto de datos

Conjunto de datos en MTL

¿Cómo entrenar un modelo MTL si no hay un dataset con todo unificado?

- 11 canales de salida
  - 1 canal Disco óptico
  - 1 canal Fóvea
  - 3 canales Arterias y Venas
  - 3 canales Cruces y bifurcaciones
  - 3 canales Anillo y Copa del Disco óptico
- Cada iteración en entrenamiento, se concatena una imagen de cada dataset.
  - Para poder hacer esto reescalamos las imágenes.
- Calculamos la pérdida de los canales que tenemos etiqueta.

Experimentación y Resultados: Detalles experimentales

- Los entrenamientos se configuran para mejorar la comparación.
- Aumento de datos:
  - Random Horizontal Flip
  - Random Vertical Flip
  - Random HSV
  - Random Affine
- Tasa de aprendizaje constante de 1×10^{-4}
- 500 épocas.
- 100 imágenes por época.
- Optimizador ADAM:
  - En MAO está implícito.

Experimentación y Resultados: Evaluación

Disco Óptico

1. Error promedio de la localización del Disco.
2. Desviación estándar.
3. Precisión en relación a un umbral.

Arterias y Venas

1. Curva ROC.
2. Curva PR.

Cruces y Bifurcaciones

1. F1-Score.
2. Precisión media.

Fóvea

1. Error promedio de la localización de la Fóvea.
2. Desviación estándar.
3. Precisión en relación a un umbral.

Anillo y Copa

1. Mean dice.
2. Mean Jaccard.
3. Curva PR.

Evaluación Cualitativa

1. Comparación imagen a imagen de las diferentes tareas.

Resultados.

Experimentación y Resultados: Cruces y Bifurcaciones

- Resultados MTL normalmente inferiores a STL.

Cruces

Modelo	f1-score	Average Precision
MultiMTL	68.12	67.54
STL	72.12	72.47

Bifurcaciones

Modelo	f1-score	Average Precision
MultiMTL	65.96	68.09
STL	67.94	68.29

Experimentación y Resultados: Cruces y Bifurcaciones

- Resultados MTL normalmente inferiores a STL.
- Multi-Decoder U-Net sin MAO supera a STL en el conjunto de cruces y bifurcaciones

Cruces y Bifurcaciones

Modelo	f1-score	Average Precision
MultiMTL	76.78	77.35
STL	74.10	75.36

Experimentación y Resultados: Cruces y Bifurcaciones

STL	U-Net MTL	U-Net MAO	Multi-Task MTL	Multi-Task MAO	Multi-Decoder MTL	Multi-Decoder MAO

Experimentación y Resultados: Disco Óptico

- Resultados MTL superiores a STL.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estándar (px)
TaskMAO	100 %	100 %	100 %	3.77	2.16

Experimentación y Resultados: Disco Óptico

- Resultados MTL superiores a STL.
- Aún así, no todos tienen resultados tan buenos.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estándar (px)
MultiMTL	100 %	100 %	95 %	5.52	3.41
UNetMTL	100 %	100 %	90 %	5.14	2.77
STL	100 %	90 %	85 %	7.81	5.90

Experimentación y Resultados: Disco Óptico

STL	U-Net MTL	U-Net MAO	Multi-Task MTL	Multi-Task MAO	Multi-Decoder MTL	Multi-Decoder MAO

Experimentación y Resultados: Fóvea

- Resultados con MAO superiores al resto de resultados.

Modelo	Precisión (R)	Precisión (R/2)	Precisión (R/4)	Error promedio (px)	Desviación estándar (px)
MultiMAO	93.14 %	88.24 %	78.43 %	16.96	37.86
TaskMAO	91.18 %	84.31 %	73.53 %	19.24	42.47

Experimentación y Resultados: Fóvea

STL	U-Net MTL	U-Net MAO	Multi-Task MTL	Multi-Task MAO	Multi-Decoder MTL	Multi-Decoder MAO

Experimentación y Resultados: Arterias y Venas

- Resultados inferiores de MTL frente STL en Venas.

Model	Venas	
	AUC-ROC (%)	AUC-PR (%)
UNetMTL	95.93	76.24
TI	97.45	84.84

Experimentación y Resultados: Arterias y Venas

- Aunque superiores o similares en Arterias y Vasos.

Model	Arterias		Vasos	
	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)
UNetMTL	97.01	82.67	97.82	91.33
TI	96.93	80.10	97.90	91.59

Experimentación y Resultados: Arterias y Venas

- Único resultado donde U-Net con MAO tiene un resultado aceptable.

Model	Venas		Arterias		Vasos	
	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)	AUC-ROC (%)	AUC-PR (%)
UNetMAO	74.01	22.54	67.94	11.87	72.22	32.56

Experimentación y Resultados: Arteras y Venas

STL	U-Net MTL	U-Net MAO	Multi-Task MTL	Multi-Task MAO	Multi-Decoder MTL	Multi-Decoder MAO

Experimentación y Resultados: Copa y Anillo

- Resultados similares o superiores e Anillo pero inferiores en Copa

Estructura	Anillo			COPA		
	mean dice (%)	mean jaccard (%)	PR-AUC (%)	mean dice (%)	mean jaccard (%)	PR-AUC (%)
MultiMAO	94.95	90.46	99.18	83.22	72.21	91.98
STL	94.51	89.73	99.14	85.69	75.52	94.87

Experimentación y Resultados: Copa y Anillo

STL	U-Net MTL	U-Net MAO	Multi-Task MTL	Multi-Task MAO	Multi-Decoder MTL	Multi-Decoder MAO

Experimentos y Resultados: Conclusiones

1. Bajo las condiciones de entrenamiento propuestas, los modelos STL son superiores.
   - Las tareas donde tarda más en empezar el sobreentrenamiento, los resultados compiten con STL.
2. MAO es dependiente de la arquitectura utilizada.
   - El mal rendimiento de la U-Net confirma esto.

(a)

(b)

(c)

(d)

(e)

(f)

(a) Pérdida total de Task-Specific U-Net (b) Disco óptico (c) Cruces y bifurcaciones (d) SSCAV (e) Fovea (f) Copa y anillo.

Tabla de contenidos

1 Introducción y Motivación

2 Estado del arte

3 Trabajo Desarrollado

4 Experimentación y Resultados

5 Conclusiones y trabajo futuro

Conclusiones

Trabajo realizado

- ☑ Se implementaron modelos MTL sin balanceo de tareas y MAO que satisfactoriamente resuelven las tareas.
- ☑ Se adaptaron las condiciones de entrenamiento para mejorar la comparación.
- ☑ Se compararon los efectos y resultados de las diferentes aproximaciones con diferentes arquitecturas.
- ☑ Se observo dificultades de MTL con MAO para arquitecturas poco específicas.
- ☑ Se planteó un posible error en la eficacia de los modelos MTL según el modo actual de entrenamiento.

Aliñamento de imaxes oftalmolóxicas usando representacións neuronais implícitas

Mateo Amado Ares

Directores: Jorge Novo Buján
José Rouco Maseda

Grupo VARPA
Departamento de Ciencias da Computación e Tecnoloxías da Información
Universidade da Coruña